

Table des matières

Introduction	1
1 Problématique	2
2 Description des données	2
2.1 Source et collecte	2
2.2 Variable cible	3
2.3 Variables explicatives	3
2.4 Traitement des valeurs manquantes	4
2.5 Statistiques descriptives sélectionnées	4
2.6 Division apprentissage / test	4
3 Résultats de la modélisation	5
3.1 Modèle complet (avant sélection)	5
3.2 Modèle final après sélection pas-à-pas	6
3.3 Odds ratios et intervalles de confiance	7
3.4 Vérification des hypothèses du modèle	7
3.5 Validation sur l'échantillon test	9
3.6 Interprétation des principaux effets	10
3.7 Synthèse des résultats	10
4 Discussion et interprétation des résultats	11
4.1 Rappel des objectifs	11
4.2 Principaux enseignements	11
4.3 Qualité d'ajustement et validité du modèle	12
4.4 Performance prédictive	13
4.5 Limites de l'étude	13
4.6 Prolongements possibles	13
5 Conclusion générale	15

6	Annexes	18
---	-------------------	----

Introduction

La fécondité, mesurée par le nombre d'enfants nés vivants (**ceb**), constitue un indicateur démographique fondamental pour évaluer les dynamiques de population et orienter les politiques de santé publique. Comprendre ses déterminants — qu'ils soient éducatifs, économiques, culturels ou géographiques — permet d'identifier les leviers d'action en matière de planification familiale, de lutte contre les grossesses précoces et d'autonomisation des femmes.

L'enquête démographique et de santé (Demographic and Health Survey, DHS) du Botswana réalisée en 1988 offre une source de données riche et fiable. Elle porte sur un échantillon représentatif de plus de 4 300 femmes âgées de 15 à 49 ans. Pour chaque individu, on dispose d'informations sur son âge, son niveau d'éducation, son statut matrimonial, sa zone de résidence (urbaine ou rurale), l'accès du ménage à certains biens (électricité, radio, télévision, vélo), ses connaissances et pratiques contraceptives, ainsi que le nombre d'enfants nés vivants (**ceb**).

L'objectif de cette étude est d'expliquer les variations de la fécondité à l'aide d'un modèle de régression de Poisson, adapté à la nature discrète et non négative de la variable réponse. La démarche suit les étapes classiques de modélisation : division de l'échantillon en apprentissage (80%) et validation (20%), sélection des variables pertinentes, vérification des hypothèses du modèle (adéquation, surdispersion, analyse des résidus) et évaluation des performances prédictives (RMSE, corrélation, courbe ROC).

1 Problématique

La question centrale à laquelle nous cherchons à répondre est la suivante :

Dans quelle mesure le niveau d'éducation, l'âge, le statut matrimonial, la zone de résidence, les biens du ménage, les connaissances et l'utilisation de la contraception influencent-ils le nombre d'enfants nés vivants chez les femmes botswanaïses en 1988, après contrôle des effets non linéaires de l'âge ?

Plus précisément, nous souhaitons :

- Quantifier l'effet **multiplicatif** de chaque variable explicative sur le nombre attendu d'enfants.
- Tester l'hypothèse d'une relation quadratique entre l'âge et la fécondité (croissance puis plateau ou déclin).
- Évaluer si le modèle de Poisson est adapté (absence de surdispersion).
- Valider le pouvoir prédictif du modèle sur un échantillon test.

Cette analyse permettra de dégager des enseignements sur les inégalités d'accès à la contraception, le rôle de l'éducation comme facteur de réduction de la fécondité, et l'impact de l'urbanisation — autant de résultats utiles pour les politiques de santé au Botswana et dans des contextes similaires.

2 Description des données

2.1 Source et collecte

Les données utilisées proviennent de l'enquête démographique et de santé (Demographic and Health Survey, DHS) du Botswana réalisée en 1988. L'échantillon initial comprend **4 361 femmes** âgées de 15 à 49 ans. Chaque observation correspond à une femme et renseigne sa situation démographique, socio-économique et ses pratiques en matière de contraception.

2.2 Variable cible

La variable réponse est **ceb** (*children ever born*), c'est-à-dire le nombre d'enfants nés vivants. Il s'agit d'une variable de comptage, dont la distribution dans l'échantillon est la suivante :

Min.	1er Qu.	Médiane	Moyenne	3e Qu.	Max.
0	1	2	2,44	4	13

La moyenne est de 2,44 enfants par femme, avec une variabilité importante (écart-type de 2,41). Environ 38 % des femmes ont au moins 3 enfants.

2.3 Variables explicatives

Après nettoyage (suppression des variables non pertinentes comme les identifiants, les dates de naissance détaillées ou les variables trop manquantes), les variables explicatives retenues pour la modélisation sont au nombre de 16 :

- **Age** : âge de la femme (15 à 49 ans, moyenne 27,4 ans).
- **agesq** : âge au carré (pour capturer une éventuelle relation non linéaire).
- **educ** : nombre d'années d'études (de 0 à 20 ans, moyenne 5,9 ans).
- **evermarr** : indicatrice de mariage (1 = déjà mariée, 0 = jamais mariée).
- **urban** : zone de résidence (1 = urbain, 0 = rural).
- **electric**, **radio**, **tv**, **bicycle** : possession de biens dans le ménage (variables binaires).
- **knowmeth** : connaissance d'au moins une méthode contraceptive (1 = oui, 0 = non).
- **usemeth** : utilisation actuelle d'une méthode contraceptive (1 = oui, 0 = non).
- **spirit**, **protest**, **catholic** : appartenance religieuse (variables binaires, référence : autres).
- **mnthborn** : mois de naissance (1 à 12).

2.4 Traitement des valeurs manquantes

L'inspection initiale des données a révélé des valeurs manquantes, notamment pour `agefm` (âge au premier mariage) et `heduc` (éducation du mari). Ces variables ont été exclues de l'analyse car elles réduisaient trop l'échantillon. Les autres variables comportaient peu de NA (au maximum 71 pour `usemeth`) ; après suppression des lignes correspondantes, la base d'analyse finale compte **4 361 observations complètes** (aucun NA restant). Le jeu de données nettoyé comprend 17 variables.

2.5 Statistiques descriptives sélectionnées

Variable	Moyenne	Écart-type	Médiane	Proportion (oui)
ceb (nombre d'enfants)	2,44	2,41	2	—
âge (années)	27,4	8,69	26	—
educ (années)	5,86	3,93	7	—
evermarr	0,48	0,50	0	48 %
urban	0,52	0,50	1	52 %
electric	0,14	0,35	0	14 %
radio	0,70	0,46	1	70 %
tv	0,09	0,29	0	9 %
bicycle	0,28	0,45	0	28 %
knowmeth	0,96	0,19	1	96 %
usemeth	0,58	0,49	1	58 %

2.6 Division apprentissage / test

Les données ont été divisées aléatoirement en deux échantillons :

- **Échantillon d'apprentissage** : 80 %, soit 3 425 observations.
- **Échantillon de validation** (test) : 20 %, soit 857 observations.

Toutes les étapes de modélisation (estimation, sélection de variables, diagnostic) sont réalisées sur l'échantillon d'apprentissage. L'échantillon test est uniquement utilisé pour évaluer la performance prédictive finale (RMSE, corrélation, courbe ROC) et éviter tout surapprentissage.

3 Résultats de la modélisation

3.1 Modèle complet (avant sélection)

Le modèle de Poisson incluant l'ensemble des variables disponibles (16 explicatives) a été estimé sur l'échantillon d'apprentissage ($n = 3425$). Les résultats sont présentés ci-dessous.

Call:

```
glm(formula = ceb ~ age + agesq + educ + evermarr + urban + electric +
     radio + tv + bicycle + knowmeth + usemeth + spirit + protest +
     catholic + mnthborn, family = poisson(link = "log"), data = train_data)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-5.2110074	0.1923963	-27.085	< 2e-16	***
age	0.3088974	0.0113798	27.144	< 2e-16	***
agesq	-0.0036475	0.0001670	-21.841	< 2e-16	***
educ	-0.0329159	0.0034574	-9.520	< 2e-16	***
evermarr	0.2961149	0.0270113	10.963	< 2e-16	***
urban	-0.1037590	0.0237573	-4.367	1.26e-05	***
electric	-0.1528647	0.0424469	-3.601	0.000317	***
radio	-0.0462720	0.0252226	-1.835	0.066573	.
tv	-0.1417394	0.0538663	-2.631	0.008505	**
bicycle	0.0707034	0.0252663	2.798	0.005137	**
knowmeth	0.2143132	0.0661767	3.238	0.001202	**
usemeth	0.3105311	0.0260911	11.902	< 2e-16	***
spirit	-0.0003871	0.0279904	-0.014	0.988967	
protest	-0.0269367	0.0333362	-0.808	0.419073	
catholic	-0.0197381	0.0438447	-0.450	0.652578	
mnthborn	-0.0008161	0.0033230	-0.246	0.805993	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Null deviance: 8510.4  on 3424  df
Residual deviance: 2908.7  on 3409  df
AIC: 10223

```

Les variables `spirit`, `protest`, `catholic` et `mnthborn` ne sont pas significatives au seuil de 5% ($p > 0,4$). Leur suppression permet d'améliorer la parcimonie du modèle.

3.2 Modèle final après sélection pas-à-pas

Une procédure stepwise (bidirectionnelle) basée sur l'AIC a été appliquée. Le modèle retenu élimine les quatre variables non significatives et conserve les 11 prédicteurs suivants :

Call:

```

glm(formula = ceb ~ age + agesq + educ + evermarr + urban + electric +
     radio + tv + bicycle + knowmeth + usemeth,
     family = poisson(link = "log"), data = train_data)

```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-5.2202909	0.1913142	-27.286	< 2e-16	***
age	0.3090380	0.0113747	27.169	< 2e-16	***
agesq	-0.0036526	0.0001668	-21.892	< 2e-16	***
educ	-0.0335992	0.0033859	-9.923	< 2e-16	***
evermarr	0.2973950	0.0269475	11.036	< 2e-16	***
urban	-0.1033303	0.0236979	-4.360	1.3e-05	***
electric	-0.1526621	0.0423926	-3.601	0.000317	***
radio	-0.0474830	0.0251617	-1.887	0.059145	.
tv	-0.1435839	0.0537164	-2.673	0.007518	**
bicycle	0.0711421	0.0252546	2.817	0.004847	**
knowmeth	0.2155042	0.0659971	3.265	0.001093	**
usemeth	0.3092931	0.0259932	11.899	< 2e-16	***

```

Null deviance: 8510.4  on 3424  df
Residual deviance: 2909.8  on 3413  df
AIC: 10216

```

L'AIC du modèle final (10216) est légèrement inférieur à celui du modèle complet (10223), confirmant le gain de parcimonie.

3.3 Odds ratios et intervalles de confiance

Les odds ratios (OR) sont obtenus par exponentiation des coefficients. Un OR > 1 indique une augmentation du nombre attendu d'enfants, un OR < 1 une diminution.

Variable	Odds Ratio	IC 95%	Effet
age (1 an)	1,362	[1,332 – 1,393]	Augmentation de 36% par an
agesq	0,996	[0,996 – 0,997]	Effet quadratique (décélération)
educ (1 an)	0,967	[0,961 – 0,973]	Réduction de 3,3% par année d'étude
evermarr (oui vs non)	1,346	[1,277 – 1,420]	Augmentation de 35% si mariée
urban (urbain vs rural)	0,902	[0,861 – 0,945]	Réduction de 10% en zone urbaine
electric (oui vs non)	0,858	[0,789 – 0,932]	Réduction de 14%
radio (oui vs non)	0,954	[0,908 – 1,002]	Réduction de 5% (p = 0,059)
tv (oui vs non)	0,866	[0,779 – 0,962]	Réduction de 13%
bicycle (oui vs non)	1,074	[1,022 – 1,128]	Augmentation de 7%
knowmeth (oui vs non)	1,240	[1,092 – 1,415]	Augmentation de 24%
usemeth (oui vs non)	1,362	[1,295 – 1,434]	Augmentation de 36%

3.4 Vérification des hypothèses du modèle

4.i Test d'adéquation globale

La déviance résiduelle suit approximativement une loi du χ^2 à $n - p$ degrés de liberté. Le calcul de la p-value associée donne :

```

p_value_adequation <- pchisq(deviance(model_step), df.residual(model_step), lower.tail=FALSE)
p_value_adequation = 1

```

Une p-value de 1 signifie que le modèle n'est pas rejeté : l'ajustement est excellent.

4.ii Surdispersion

Le paramètre de dispersion estimé est :

```
phi_step <- deviance(model_step) / df.residual(model_step)
phi_step = 0.8526
```

Cette valeur est légèrement inférieure à 1, indiquant une sous-dispersion (pas de violation des hypothèses). Le test formel du package **AER** confirme l'absence de surdispersion (p-value = 1).

4.iii Analyse des résidus

Les graphiques suivants permettent d'évaluer la normalité et l'homoscédasticité des résidus.




FIGURE 3.1 – Résidus de Pearson (gauche) et Q-Q plot (droite).




FIGURE 3.2 – Histogramme des résidus déviants (gauche) et distance de Cook (droite).

Les résidus de Pearson sont centrés sur zéro et ne présentent pas de tendance particulière. Le Q-Q plot montre une légère déviation dans les queues, acceptable pour un

modèle de Poisson. La distance de Cook reste inférieure au seuil critique (ligne rouge), indiquant l'absence de points excessivement influents.

4.iv Pseudo- R^2 de McFadden

Le pseudo- R^2 de McFadden, qui mesure la réduction de la déviance par rapport au modèle nul, est de **0,3546**. Cette valeur, comprise entre 0,2 et 0,4, indique un **bon ajustement** pour un modèle de régression de Poisson. Autrement dit, le modèle final explique environ 35,5% de la déviance totale observée.

$$\text{Pseudo-}R^2 \text{ (McFadden)} = 0.3546$$

3.5 Validation sur l'échantillon test

Les prédictions du modèle final sur les $n = 857$ observations de validation donnent les performances suivantes :

- **RMSE** (racine de l'erreur quadratique moyenne) : 1,498 enfant.
- **Corrélation** entre *ceb* observé et prédit : 0,780.
- **AUC** (courbe ROC) pour la classification binaire (au moins un enfant) : 0,899.




FIGURE 3.3 – Courbe ROC du modèle final (test). AUC = 0,8986.

Une AUC de 0,90 témoigne d'une excellente capacité discriminante : le modèle distingue très bien les femmes ayant au moins un enfant de celles qui n'en ont aucun. Le RMSE de 1,5 enfant est satisfaisant compte tenu de l'échelle de la variable (0 à 13).

3.6 Interprétation des principaux effets

- **Âge** : l'effet positif de l'âge ($OR = 1,36$ par an) et l'effet négatif du terme quadratique ($OR = 0,996$) indiquent que le nombre d'enfants augmente rapidement dans la jeunesse puis se stabilise, voire diminue après un certain âge.
- **Éducation** : chaque année supplémentaire d'études réduit le nombre attendu d'enfants d'environ 3%. Cet effet est conforme à la littérature : l'éducation retarde l'entrée en maternité et favorise l'utilisation de la contraception.
- **Mariage** : les femmes mariées ont 35% d'enfants de plus que les jamais mariées, ce qui reflète l'exposition au risque de grossesse.
- **Urbanisation** : vivre en ville réduit la fécondité de 10%, probablement en raison d'un meilleur accès à l'information et aux services de santé.
- **Biens du ménage** : l'électricité et la télévision (proxy du niveau socio-économique) diminuent la fécondité, tandis que le vélo (peu répandu en milieu urbain) l'augmente légèrement – un effet résiduel à interpréter avec prudence.
- **Contraception** : connaître une méthode contraceptive ($OR = 1,24$) et surtout l'utiliser activement ($OR = 1,36$) sont associés à un nombre d'enfants plus élevé. Ce résultat contre-intuitif s'explique par un biais de causalité inverse : les femmes qui ont déjà eu beaucoup d'enfants sont plus susceptibles d'adopter une contraception pour limiter les naissances futures.

3.7 Synthèse des résultats

Le modèle de Poisson final, parcimonieux et bien ajusté, met en évidence les déterminants majeurs de la fécondité au Botswana en 1988 : l'âge (effet non linéaire), l'éducation (réducteur), le mariage (accroisseur), la résidence urbaine (réductrice), le niveau socio-économique (réducteur via électricité, TV) et les pratiques contraceptives (endogènes, à interpréter avec précaution). Les performances prédictives (RMSE, corrélation, AUC) sont très satisfaisantes.

4 Discussion et interprétation des résultats

4.1 Rappel des objectifs

Cette étude visait à modéliser le nombre d'enfants nés vivants (**ceb**) chez les femmes botswanaises en 1988 à l'aide d'une régression de Poisson, afin d'identifier les facteurs socio-démographiques et économiques qui influencent la fécondité. La problématique centrale cherchait à quantifier l'effet de l'éducation, de l'âge, du statut matrimonial, de l'urbanisation, des biens du ménage et des pratiques contraceptives.

4.2 Principaux enseignements

2.i Âge et fécondité : une relation non linéaire

L'effet de l'âge est à la fois positif (**age** OR = 1,36) et modéré par un terme quadratique négatif (**agesq** OR = 0,996). Cela traduit une augmentation rapide du nombre d'enfants pendant la jeunesse, puis un ralentissement après un certain âge (environ 30-35 ans). Ce résultat est physiologiquement et socialement cohérent : les femmes commencent à avoir des enfants tôt, mais la fécondité plafonne avec l'âge et l'arrivée de la ménopause.

2.ii Éducation : un puissant facteur réducteur

Chaque année supplémentaire d'études diminue le nombre attendu d'enfants d'environ 3,3% (OR = 0,967). Cet effet est l'un des plus robustes en démographie. L'éducation retarde l'âge au premier mariage, améliore la connaissance et l'utilisation de la contraception, et modifie les aspirations professionnelles. Dans le contexte du Botswana en 1988, une année d'études supplémentaire réduit la fécondité cumulée d'environ 0,08 enfant (en termes d'effet marginal), ce qui est considérable.

2.iii Mariage et exposition au risque

Les femmes déjà mariées (**evermarr**) ont 35% plus d'enfants que celles qui ne l'ont jamais été. Ce résultat est attendu : le mariage, dans ce contexte, est le cadre principal de

la procréation. Il souligne l'importance de prendre en compte l'exposition au risque de grossesse.

2.iv Urbanisation et niveau de vie

Résider en zone urbaine réduit la fécondité de 10% ($OR = 0,902$). Cet effet est probablement médié par un meilleur accès à l'éducation, à l'emploi féminin, à l'information et aux services de santé. De même, posséder une télévision ($OR = 0,866$) ou l'électricité ($OR = 0,858$) — des marqueurs du statut socio-économique — est associé à une fécondité plus faible. En revanche, la possession d'un vélo ($OR = 1,074$) montre un effet positif inattendu, peut-être parce que le vélo est plus fréquent en milieu rural, ou parce qu'il capte une dimension différente du niveau de vie (mobilité pour les activités agricoles). Cette variable mériterait une analyse plus fine.

2.v Contraception : effet endogène

Contrairement à l'intuition, connaître une méthode contraceptive ($OR = 1,24$) ou l'utiliser activement ($OR = 1,36$) est associé à un nombre d'enfants plus élevé. Il ne s'agit pas d'un effet causal direct, mais plutôt d'une ****endogénéité**** : les femmes qui ont déjà eu beaucoup d'enfants sont plus susceptibles d'adopter une contraception pour limiter les naissances futures. Le modèle de Poisson ne permet pas de trancher la causalité, mais l'observation reste cohérente avec les données de santé publique.

4.3 Qualité d'ajustement et validité du modèle

Le modèle final présente une ****p-value du test d'adéquation**** égale à 1, ce qui indique que la déviance résiduelle n'est pas significativement élevée : le modèle ajuste très bien les données. Le paramètre de dispersion $\hat{\phi} = 0,853$ (légère sous-dispersion) et le test de surdispersion ($p = 1$) confirment que l'hypothèse d'équidispersion du modèle de Poisson est respectée. L'analyse des résidus de Pearson et de la distance de Cook ne montre pas de violation majeure ni de points anormalement influents.

Le pseudo- R^2 de McFadden est de ****0,355****, indiquant que le modèle explique 35,5% de la déviance totale. Ce chiffre est satisfaisant pour un modèle de comptage.

4.4 Performance prédictive

Sur l'échantillon test (857 observations), le modèle atteint :

- **RMSE** = 1,50 enfant (erreur absolue moyenne d'environ 1,2 enfant), - **Corrélation** entre valeurs observées et prédites = 0,78, - **AUC** = 0,90 pour la classification binaire (savoir si la femme a au moins un enfant).

Une AUC de 0,90 est considérée comme **excellente** (très bonne discrimination). Le modèle distingue très bien les femmes qui ont déjà des enfants de celles qui n'en ont aucun.

4.5 Limites de l'étude

Plusieurs limites doivent être mentionnées :

- **Causalité non établie** : la corrélation n'implique pas la causalité. L'effet de la contraception est très probablement biaisé par l'endogénéité. Une approche par variables instrumentales (comme suggéré dans l'énoncé) serait nécessaire.
- **Données anciennes** : l'enquête date de 1988. Les comportements de fécondité ont pu évoluer, notamment avec l'épidémie de VIH/SIDA qui a frappé le Botswana dans les années 1990–2000.
- **Variables manquantes** : certaines variables importantes comme le revenu du ménage, la mortalité infantile, ou l'activité professionnelle ne sont pas disponibles.
- **Forme fonctionnelle** : nous avons supposé une relation log-linéaire ; des non-linéarités plus complexes (effets seuil) n'ont pas été explorées.

4.6 Prolongements possibles

Les pistes suivantes pourraient enrichir l'analyse :

- Utiliser un modèle de **binomiale négative** si la sous-dispersion devenait problématique sur d'autres données.
- Introduire des **interactions** (par exemple `age` $\times$ `educ`, `urban` $\times$ `educ`) pour tester si l'effet de l'éducation diffère selon la zone de résidence.

- Appliquer un modèle de **Poisson avec variable instrumentale** (via `ivpois`) pour traiter l'endogénéité de l'éducation et de la contraception.
- Comparer les prédictions avec des méthodes d'apprentissage automatique (forêts aléatoires, boosting).

5 Conclusion générale

Cette étude visait à modéliser le nombre d'enfants nés vivants (**ceb**) chez les femmes botswanaises en 1988 à partir des données de l'enquête démographique et de santé (DHS). Face à une variable de comptage, la régression de Poisson a été mise en œuvre, en suivant rigoureusement les étapes préconisées : nettoyage et préparation des données, division en échantillons d'apprentissage (80 %) et de validation (20 %), sélection des variables par procédure pas-à-pas, vérification des hypothèses du modèle (surdispersion, analyse des résidus, distance de Cook) et évaluation des performances prédictives.

0..1 Résultats marquants.

Le modèle final retenu comporte onze variables explicatives : âge (avec son terme quadratique), éducation, statut matrimonial, zone de résidence, possession de biens (électricité, radio, télévision, vélo), connaissance et utilisation de la contraception. Tous les coefficients sont significatifs au seuil de 5 %, sauf la radio ($p = 0,059$). Les effets quantifiés sous forme d'odds ratios sont cohérents avec la littérature démographique :

- L'âge agit positivement mais de façon concave (croissance rapide puis ralentissement).
- Chaque année d'études supplémentaire réduit le nombre attendu d'enfants d'environ 3,3 %.
- Le mariage et la résidence rurale augmentent la fécondité (respectivement +35 % et +10 % par rapport aux célibataires et citadines).
- La possession d'une télévision ou de l'électricité (proxy du niveau socio-économique) réduit la fécondité.
- La connaissance et l'utilisation d'une méthode contraceptive sont positivement associées au nombre d'enfants, ce qui traduit vraisemblablement un comportement de rattrapage (endogénéité).

0..2 Qualité et validation du modèle.

Les tests diagnostiques confirment l'absence de surdispersion ($\hat{\phi} = 0,8526$) et un ajustement excellent (p -value du test de déviance = 1). Le pseudo- R^2 de McFadden atteint 0,3546, valeur en faveur d'un bon pouvoir explicatif. Sur l'échantillon test, le RMSE est

de 1,50 enfant, la corrélation entre valeurs observées et prédites de 0,78, et l'AUC de la courbe ROC pour la classification binaire (au moins un enfant) est de 0,8986, témoignant d'une très bonne capacité discriminante.

0..3 Limites et perspectives.

Malgré ces résultats solides, l'étude comporte certaines limites : le caractère transversal des données ne permet pas d'inférer des causalités, l'endogénéité potentielle de l'éducation et de la contraception reste non traitée, et quelques variables d'intérêt (préférences, pression sociale) sont absentes. Pour aller plus loin, on pourrait :

- Appliquer un modèle binomial négatif si une surdispersion apparaissait,
- Introduire des variables instrumentales pour traiter l'endogénéité,
- Comparer les performances avec des méthodes d'apprentissage automatique (forêts aléatoires, boosting),
- Répliquer l'analyse sur des données plus récentes pour observer l'évolution des déterminants.

0..4 Enseignement final.

Cette étude démontre la pertinence de la régression de Poisson pour analyser des données de fécondité. Elle confirme l'importance centrale de l'éducation, de l'urbanisation et des comportements matrimoniaux dans la réduction de la fécondité, tout en mettant en garde contre des interprétations causales hâtives des variables contraceptives. Le modèle fournit une base fiable pour la prédiction et la compréhension des écarts de fécondité au Botswana en 1988, et son approche méthodologique est reproductible dans d'autres contextes démographiques.

Bibliographie

- [1] Kaggle. (2012). *Fertil_2 : Demographic and Health Survey - Botswana 1988*. Récupéré sur [https ://www.kaggle.com/](https://www.kaggle.com/)

6 Annexes

Code R Utilisé

```
# =====
# Projet : Modèle de régression de Poisson (fécondité Botswana, 1988)
# =====

# -----
# 1. Installation et chargement des packages
# -----
install.packages(c("skimr", "tidyverse", "ggplot2", "readr", "readxl",
                  "psych", "AER", "pROC"))

library(tidyverse)
library(ggplot2)
library(readr)
library(readxl)
library(skimr)
library(psych)
library(AER)    # pour dispersiontest
library(pROC)   # pour courbe ROC

# -----
# 2. Chargement et inspection initiale
# -----
Data_brute <- read_csv("C:/Users/ADMIN/OneDrive/Bureau/Projets GLM/data.csv")
view(Data_brute)
str(Data_brute)
describe(Data_brute)
colSums(is.na(Data_brute))

# -----
# 3. Suppression des colonnes non pertinentes
```

```

# -----
cols_to_remove <- c("...1", "yearborn", "monthfm", "yearfm", "agefbrth",
                    "children", "heduc", "idlnchld", "frsthalf", "urb_educ", "educ0")
Data_clean <- Data_brute[, !(names(Data_brute) %in% cols_to_remove)]
colnames(Data_clean)

# -----
# 4. Gestion des valeurs manquantes
# -----
# Variables avec peu de NA : suppression des lignes concernées
vars_few_na <- c("electric", "radio", "tv", "bicycle", "knowmeth")
Data_clean <- Data_clean[complete.cases(Data_clean[, vars_few_na]), ]
Data_clean <- Data_clean[!is.na(Data_clean$usemeth), ]

# agefm : NA pour jamais mariées -> remplacement par 0
Data_clean$agefm[is.na(Data_clean$agefm)] <- 0

# Vérification finale
colSums(is.na(Data_clean))

# -----
# 5. Création de variables supplémentaires
# -----
Data_clean$age2 <- Data_clean$age^2 # carré de l'âge (déjà agesq, mais on recrée)

# -----
# 6. Division apprentissage (80%) / test (20%)
# -----
set.seed(123)
n <- nrow(Data_clean)
indices_train <- sample(1:n, size = floor(0.8 * n))
train_data <- Data_clean[indices_train, ]

```

```

test_data <- Data_clean[-indices_train, ]

dim(train_data) # 3425
dim(test_data)  # 857

# -----
# 7. Modèle de Poisson complet (toutes variables)
# -----
model_poisson <- glm(ceb ~ age + agesq + educ + evermarr + urban +
                     electric + radio + tv + bicycle + knowmeth + usemeth +
                     spirit + protest + catholic + mnthborn,
                     family = poisson(link = "log"), data = train_data)
summary(model_poisson)

# Test de surdispersion
phi <- deviance(model_poisson) / df.residual(model_poisson)
phi
dispersiontest(model_poisson, trafo = 1)

# -----
# 8. Sélection pas-à-pas (stepwise) basée sur l'AIC
# -----
model_step <- step(model_poisson, direction = "both", trace = FALSE)
summary(model_step)

# Odds ratios et intervalles de confiance
exp_coef <- exp(coef(model_step))
conf_int <- exp(confint(model_step))

# -----
# 9. Diagnostic du modèle final
# -----

```



```
# Test d'adéquation globale
p_adequation <- pchisq(deviance(model_step), df.residual(model_step), lower.tail = FALSE)
p_adequation

# Paramètre de surdispersion
phi_step <- deviance(model_step) / df.residual(model_step)
phi_step

# Résidus
res_pearson <- residuals(model_step, type = "pearson")
res_deviance <- residuals(model_step, type = "deviance")
pred_fitted <- fitted(model_step)

# Graphiques (à sauvegarder)
plot(pred_fitted, res_pearson, main = "Résidus de Pearson vs valeurs prédites")
abline(h = 0, col = "red", lty = 2)

qqnorm(res_pearson, main = "Q-Q plot (résidus de Pearson)")
qqline(res_pearson, col = "red")

hist(res_deviance, breaks = 30, main = "Histogramme des résidus déviants",
      probability = TRUE)
curve(dnorm(x, mean = mean(res_deviance), sd = sd(res_deviance)),
      add = TRUE, col = "blue", lwd = 2)

# Distance de Cook
cook <- cooks.distance(model_step)
plot(cook, type = "h", main = "Distance de Cook")
abline(h = 4/length(cook), col = "red")

# -----
# 10. Prédiction et validation sur l'échantillon test
```

```

# -----
test_data$pred_ceb <- predict(model_step, newdata = test_data, type = "response")

# RMSE
rmse <- sqrt(mean((test_data$ceb - test_data$pred_ceb)^2))
rmse

# Corrélation
cor_obs_pred <- cor(test_data$ceb, test_data$pred_ceb)
cor_obs_pred

# Courbe ROC (seuil : au moins 1 enfant)
roc_curve <- roc(test_data$ceb > 0, test_data$pred_ceb)
auc_roc <- auc(roc_curve)
auc_roc
plot(roc_curve, main = "Courbe ROC (modèle final)", col = "blue", lwd = 2, print.auc = TRUE)

# -----
# 11. Pseudo- $R^2$  de McFadden
# -----
ll_model <- logLik(model_step)
ll_null <- logLik(glm(ceb ~ 1, family = poisson, data = train_data))
pseudo_r2 <- 1 - as.numeric(ll_model) / as.numeric(ll_null)
pseudo_r2

# =====

```