



ROYAUME DU MAROC
HAUT COMMISSARIAT AU PLAN
INSTITUT NATIONAL DE STATISTIQUE
ET D'ÉCONOMIE APPLIQUÉE
INSEA



ANALYSE DES DÉTERMINANTS SOCIO- DÉMOGRAPHIQUES DE LA SURVIE LORS DU NAUFRAGE DU TITANIC : UNE APPROCHE PAR RÉGRESSION LOGISTIQUE

Réalisé par : GUERGOU G. Abdoul-Samah
Economie Appliquée Statistique et Big Data

Encadré par : Mme. BADAoui FADOUA

Table des matières

Introduction	1
1 Problématique	2
2 Description des données	3
2.1 Statistiques descriptives préliminaires	4
3 Résultats obtenus	5
3.1 Partition des données et prétraitement	5
3.2 Construction et sélection du modèle	5
3.3 Tests d'adéquation du modèle	6
3.4 Analyse des résidus	7
3.5 Validation et comparaison des modèles	9
3.6 Odds ratios du modèle AIC (Stepwise)	10
4 Discussion et interprétation des résultats	12
4.1 Synthèse des principaux résultats	12
4.2 Validation des hypothèses de recherche	12
4.3 Comparaison des modèles AIC et BIC	14
4.4 Limites de l'étude	14
4.5 Implications et portée des résultats	15
5 Conclusion	16
6 Webographie	18
7 Annexes	19

Introduction

Le naufrage du RMS Titanic, survenu dans la nuit du 14 au 15 avril 1912 lors de sa traversée inaugurale, demeure l'une des catastrophes maritimes les plus marquantes de l'histoire moderne. Sur les 2224 passagers et membres d'équipage à bord, 1502 périrent dans les eaux glacées de l'Atlantique Nord, tandis que seulement 722 survécurent. Ce drame a profondément marqué les esprits et conduit à l'adoption de nouvelles réglementations internationales en matière de sécurité maritime, notamment concernant le nombre obligatoire de canots de sauvetage.

Au-delà de l'aspect historique, la catastrophe du Titanic constitue un cas d'étude privilégié en science des données et en statistique appliquée. La base de données associée, mise à disposition sur la plateforme Kaggle, recense les caractéristiques individuelles de 1309 passagers. Elle permet d'explorer une question fondamentale : certains groupes de passagers étaient-ils plus susceptibles de survivre que d'autres ? Cette interrogation soulève des enjeux à la fois méthodologiques et socio-historiques.

La régression logistique est particulièrement adaptée à ce type de problématique. Contrairement à la régression linéaire classique, elle permet de modéliser une variable réponse binaire (survie ou décès) en fonction de plusieurs variables explicatives, qu'elles soient quantitatives ou qualitatives. Le modèle estime la probabilité d'appartenance à la classe des survivants, puis, via l'application d'un seuil de décision, attribue une classe prédite à chaque observation. L'interprétation des coefficients du modèle, via les odds ratios, offre une compréhension fine de l'influence de chaque facteur sur les chances de survie.

Ce travail s'inscrit dans le cadre d'un TP de modélisation statistique. L'objectif est d'appliquer rigoureusement la méthodologie de la régression logistique sous R, en suivant les étapes classiques : partition des données, construction du modèle sur un échantillon d'apprentissage, tests d'adéquation, analyse des résidus et validation sur un échantillon test. Au-delà de l'aspect purement prédictif, ce TP vise à développer une démarche analytique complète, depuis la formulation d'une problématique jusqu'à l'interprétation critique des résultats.

1 Problématique

La problématique centrale de cette étude est la suivante :

« Dans quelle mesure les facteurs démographiques et socio-économiques des passagers du Titanic permettent-ils d'expliquer et de prédire leur probabilité de survie ? »

Pour répondre à cette question, nous formulons les hypothèses de recherche suivantes :

1. **Hypothèse 1 (Genre)** : Les femmes ont une probabilité de survie significativement plus élevée que les hommes, en raison de la politique d'évacuation « les femmes et les enfants d'abord » appliquée lors du naufrage.
2. **Hypothèse 2 (Classe sociale)** : La classe de voyage (`pclass`), indicateur du statut socio-économique, influence fortement la survie. Les passagers de première classe, plus proches du pont des canots et bénéficiant d'un accès prioritaire, devraient présenter un taux de survie supérieur à ceux de deuxième et troisième classes.
3. **Hypothèse 3 (Âge)** : L'âge constitue un facteur discriminant. Les enfants en bas âge, prioritaires lors de l'évacuation, devraient avoir une probabilité de survie plus élevée que les adultes et les personnes âgées.
4. **Hypothèse 4 (Structure familiale)** : La présence de membres de la famille à bord (variables `sibsp` et `parch`) peut influencer la survie, soit positivement (entraide familiale), soit négativement (difficulté à se coordonner dans la panique).

L'analyse sera conduite en suivant rigoureusement le canevas méthodologique prescrit :

- Partition stratifiée des données en échantillons d'apprentissage (80%) et de validation (20%) ;
- Construction d'un modèle de régression logistique par sélection progressive des variables ;
- Évaluation de l'adéquation du modèle via les pseudo- R^2 ;
- Analyse diagnostique des résidus (Pearson, déviance, distance de Cook) ;

- Comparaison des modèles candidats (AIC vs BIC) sur la base des matrices de confusion et des courbes ROC ;
- Interprétation des résultats à la lumière du contexte historique.

2 Description des données

Les données utilisées dans cette étude proviennent de la base *Titanic : Machine Learning from Disaster*, disponible sur la plateforme Kaggle. Le jeu de données initial comporte 1309 observations et 14 variables, détaillées dans le tableau ci-dessous.

TABLE 2.1 – Dictionnaire des variables du jeu de données Titanic

Variable	Type	Description
<code>pclass</code>	Qualitatif ordinal	Classe de voyage (1 = 1 ^{ère} , 2 = 2 ^{nde} , 3 = 3 ^{ème})
<code>survived</code>	Qualitatif binaire	Statut de survie (0 = Décédé, 1 = Survivant)
<code>name</code>	Texte	Nom complet du passager
<code>sex</code>	Qualitatif binaire	Sexe (f emale / m ale)
<code>age</code>	Quantitatif continu	Âge en années (fractionnel si < 1 an)
<code>sibsp</code>	Quantitatif discret	Nombre de frères/sœurs ou conjoints à bord
<code>parch</code>	Quantitatif discret	Nombre de parents ou enfants à bord
<code>ticket</code>	Texte	Numéro du ticket
<code>fare</code>	Quantitatif continu	Tarif payé (en livres sterling)
<code>cabin</code>	Texte	Numéro de cabine
<code>embarked</code>	Qualitatif nominal	Port (C = Cherbourg, Q = Queenstown, S = Southampton)
<code>boat</code>	Texte	Numéro du canot de sauvetage
<code>body</code>	Quantitatif	Numéro d'identification du corps retrouvé
<code>home.dest</code>	Texte	Destination finale

Remarque préliminaire : Les variables `boat` (canot de sauvetage), `body` (numéro de corps) et `cabin` (cabine) ne sont pas exploitables dans un cadre prédictif. Les deux premières constituent des informations postérieures au naufrage et introduiraient un biais de « fuite de données » (*data leakage*) si elles étaient incluses dans le modèle. La variable `cabin` présente par ailleurs un taux de valeurs manquantes supérieur à 77%, rendant son utilisation peu pertinente. Ces variables, ainsi que `ticket`, `name` et `home.dest`, seront écartées de l'analyse.

2.1 Statistiques descriptives préliminaires

Le jeu de données complet (avant nettoyage et partition) présente les caractéristiques suivantes :

- **Variable cible (survived)** : Le taux de survie global est de 38,2%. La distribution est modérément déséquilibrée, avec une proportion plus élevée de non-survivants (61,8%) que de survivants.
- **Âge (age)** : 263 valeurs manquantes (20,1% de l'effectif total) sont à dénombrer. L'âge moyen des passagers renseignés est de 29,9 ans, avec un écart-type de 14,4 ans. La distribution s'étend de 0,17 an (2 mois) à 80 ans.
- **Tarif (fare)** : Une valeur manquante est recensée. La distribution est fortement asymétrique, avec une médiane à 14,45 livres sterling et un maximum à 512,33 livres sterling.
- **Port d'embarquement (embarked)** : Deux valeurs manquantes sont présentes. La majorité des passagers ont embarqué à Southampton (mode = S).

Ces valeurs manquantes feront l'objet d'un traitement par imputation après la partition des données en échantillons d'apprentissage et de validation, conformément aux bonnes pratiques méthodologiques visant à prévenir toute contamination de l'échantillon test par les statistiques de l'échantillon d'apprentissage.

3 Résultats obtenus

3.1 Partition des données et prétraitement

Conformément au protocole établi, les données ont été divisées en un échantillon d'apprentissage (80%) et un échantillon de validation (20%), avec stratification sur la variable cible `survived` afin de préserver la proportion de survivants dans les deux sous-ensembles.

TABLE 3.1 – Répartition des échantillons après partition stratifiée

Échantillon	Effectif	Survivants (%)	Non-survivants (%)
Complet	1309	38,20%	61,80%
Apprentissage (Train)	1048	37,79%	62,21%
Validation (Test)	261	39,85%	60,15%

Les variables non pertinentes (`boat`, `body`, `cabin`, `ticket`, `name`, `home.dest`) ont été retirées. Les valeurs manquantes ont été traitées sur l'échantillon d'apprentissage puis les paramètres d'imputation ont été appliqués à l'échantillon de validation.

TABLE 3.2 – Traitement des valeurs manquantes

Variable	NA (Train)	Méthode d'imputation
<code>age</code>	212 (20,2%)	Médiane conditionnelle selon <code>pclass</code> $\times$ <code>sex</code>
<code>embarked</code>	2 (0,2%)	Mode (valeur la plus fréquente : S)
<code>fare</code>	1 (0,1%)	Médiane

3.2 Construction et sélection du modèle

2.i Modèle complet

Un premier modèle de régression logistique incluant l'ensemble des variables explicatives disponibles a été ajusté sur l'échantillon d'apprentissage.

```
glm(survived ~ pclass + sex + age + sibsp + parch + fare + embarked,
    data = train_data, family = binomial)
```

Les variables `parch` ($p = 0,622$) et `fare` ($p = 0,981$) ne sont pas significatives au seuil de 5%.

TABLE 3.3 – Coefficients estimés du modèle complet

Variable	Estimation	Écart-type	Valeur z	p-value
(Intercept)	4,357	0,458	9,517	$< 2 \times 10^{-16}$ ***
pclass2	-1,233	0,282	-4,368	$1,25 \times 10^{-5}$ ***
pclass3	-2,333	0,293	-7,962	$1,70 \times 10^{-15}$ ***
sexmale	-2,481	0,179	-13,885	$< 2 \times 10^{-16}$ ***
age	-0,043	0,008	-5,637	$1,73 \times 10^{-8}$ ***
sibsp	-0,288	0,100	-2,877	0,00402 **
parch	-0,050	0,102	-0,493	0,62219
fare	$-5,6 \times 10^{-5}$	0,002	-0,023	0,98127
embarkedQ	-0,469	0,332	-1,411	0,15833
embarkedS	-0,635	0,210	-3,015	0,00257 **

Significativité : *** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$

2.ii Sélection automatique des variables

Une procédure de sélection pas à pas (*stepwise*) basée sur le critère AIC a été appliquée. Le modèle final retenu après cette procédure est :

```
survived ~ pclass + sex + age + sibsp + embarked
```

Une seconde sélection basée sur le critère BIC, plus pénalisant, a conduit au modèle suivant :

```
survived ~ pclass + sex + age + sibsp
```

Le tableau 3.4 présente les caractéristiques des deux modèles candidats retenus pour la validation.

TABLE 3.4 – Comparaison des modèles candidats

Modèle	Variables incluses	AIC	BIC	Deviance résiduelle
AIC (Stepwise)	pclass + sex + age + sibsp + embarked	973,52	1013,16	957,52 (1040 dl)
BIC	pclass + sex + age + sibsp	978,83	1008,56	966,83 (1042 dl)

3.3 Tests d'adéquation du modèle

3.i Test de surdispersion

Avant de procéder aux tests d'adéquation, la présence de surdispersion a été vérifiée pour les deux modèles. Le paramètre de dispersion ϕ est estimé par le rapport

entre la déviance résiduelle et le nombre de degrés de liberté résiduels.

TABLE 3.5 – Test de surdispersion

Modèle	Déviance résiduelle	ddl résiduels	Paramètre ϕ
Modèle complet	957,26	1038	0,9222
Modèle AIC	957,52	1040	0,9207

Les paramètres de dispersion ϕ sont très proches de 1 (légèrement inférieurs), indiquant une absence de surdispersion. Le modèle logistique standard avec la famille binomiale est donc parfaitement approprié.

3.ii Test de Hosmer-Lemeshow

Le test de Hosmer-Lemeshow appliqué au modèle AIC donne les résultats suivants :

Hosmer and Lemeshow goodness of fit (GOF) test

X-squared = 22,003 ; df = 8 ; p-value = 0,00491

La p-value inférieure à 0,05 indique formellement une mauvaise adéquation. Cependant, ce test est connu pour être excessivement sensible avec les grands échantillons ($n > 1000$), rejetant fréquemment l'hypothèse nulle même pour des modèles bien ajustés.

3.iii Pseudo- R^2

TABLE 3.6 – Pseudo- R^2 du modèle AIC

Indicateur	Valeur
R^2 de McFadden	0,311
R^2 de Nagelkerke	0,460

Les valeurs des pseudo- R^2 indiquent un pouvoir explicatif satisfaisant, le modèle capturant entre 31% et 46% de la variabilité de la survie.


3.4 Analyse des résidus

L'analyse des résidus a été conduite sur l'échantillon d'apprentissage pour le modèle AIC.

TABLE 3.7 – Statistiques descriptives des résidus de Pearson et de déviance

Type de résidu	Min	1 ^{er} Qu.	Médiane	Moyenne	Max
Pearson	-5,208	-0,492	-0,316	0,023	5,082
Déviance	-2,583	-0,658	-0,437	-0,057	2,565

- Des résidus de Pearson extrêmes ($|r| > 3$) sont observés pour 51 observations (4,9% de l'échantillon).
- L'analyse des distances de Cook identifie 49 observations potentiellement influentes (seuil = $4/n = 0,0038$), correspondant principalement à des cas de survie atypiques.
- La distribution des résidus est approximativement symétrique et centrée sur zéro, ce qui est satisfaisant.

**FIGURE 3.1** – Graphiques diagnostiques des résidus du modèle AIC

3.5 Validation et comparaison des modèles

Les deux modèles candidats (AIC et BIC) ont été évalués sur l'échantillon de validation à l'aide des matrices de confusion et des courbes ROC.

5.i Matrices de confusion

TABLE 3.8 – Matrices de confusion sur l'échantillon test ($n = 261$)

	Modèle AIC		Modèle BIC	
	Prédit		Prédit	
Réel	0	1	0	1
0	132	25	134	23
1	34	70	32	72

TABLE 3.9 – Métriques de performance comparées

Métrique	Modèle AIC	Modèle BIC
Exactitude (<i>Accuracy</i>)	77,39%	78,93%
Sensibilité (<i>Recall</i>)	67,31%	69,23%
Spécificité	84,08%	85,35%
Précision (<i>Precision</i>)	73,68%	75,79%
<i>F1-Score</i>	0,7035	0,7236

5.ii Courbes ROC

TABLE 3.10 – Aires sous la courbe ROC (AUC)

Modèle	AUC	IC à 95%
AIC	0,8498	[0,8006 ; 0,8990]
BIC	0,8473	—

Le test de DeLong pour la comparaison des deux courbes ROC donne une p-value de 0,7372, indiquant l'absence de différence statistiquement significative entre les AUC des deux modèles.




FIGURE 3.2 – Courbes ROC comparées des modèles AIC et BIC

3.6 Odds ratios du modèle AIC (Stepwise)

Le tableau 3.12 présente les odds ratios estimés pour le modèle AIC retenu.

TABLE 3.11 – Sortie des odds ratios (format R)

exp(coef(modele_stepwise))						
(Intercept)	pclass2	pclass3	sexmale	age	sibsp	
75.43448073	0.29208165	0.09706955	0.08529603	0.95821552	0.73879434	
embarkedQ	embarkedS					
0.63861286	0.52999889					

TABLE 3.12 – Odds ratios du modèle AIC (Stepwise)

Variable	Odds Ratio	Interprétation
sexmale	0,085	Les hommes ont 91,5% de chances en moins de survivre que les femmes
pclass3	0,097	La 3 ^{ème} classe a 90,3% de chances en moins que la 1 ^{ère}
pclass2	0,292	La 2 nd e classe a 70,8% de chances en moins que la 1 ^{ère}
age	0,958	Chaque année supplémentaire réduit les chances de survie de 4,2%
sibsp	0,739	Chaque membre de fratrie/conjoint réduit les chances de 26,1%
embarkedQ	0,639	Embarquer à Queenstown réduit les chances de 36,1% (vs Cherbourg)
embarkedS	0,530	Embarquer à Southampton réduit les chances de 47,0% (vs Cherbourg)

Note : L'*odds ratio* de l'ordonnée à l'origine (Intercept = 75,43) n'a pas d'interprétation pratique directe ; il correspond aux chances de survie pour un passager de référence (femme, 1^{ère} classe, âge 0, sans famille, embarqué à Cherbourg).

4 Discussion et interprétation des résultats

4.1 Synthèse des principaux résultats

L'analyse de régression logistique menée sur les données du naufrage du Titanic a permis de mettre en évidence plusieurs facteurs déterminants de la survie des passagers. Le tableau 4.1 synthétise l'effet de chaque variable retenue dans le modèle AIC final.

TABLE 4.1 – Synthèse des effets des variables explicatives sur la probabilité de survie

Variable	Significativité	Odds Ratio	Effet sur la survie
sex (masculin)	$p < 0,001$	0,085	Très fortement négatif
pclass (3 ^{ème})	$p < 0,001$	0,097	Très fortement négatif
pclass (2 ^{nde})	$p < 0,001$	0,292	Fortement négatif
age	$p < 0,001$	0,958	Modérément négatif
sibsp	$p = 0,001$	0,739	Modérément négatif
embarked (S)	$p = 0,002$	0,530	Modérément négatif
embarked (Q)	$p = 0,173$	0,639	Non significatif

4.2 Validation des hypothèses de recherche

2.i Hypothèse 1 : Effet du genre

L'hypothèse selon laquelle les femmes ont une probabilité de survie significativement plus élevée que les hommes est **fortement confirmée**. Avec un odds ratio de 0,085 ($p < 0,001$), le modèle indique que les hommes avaient environ 91,5% de chances en moins de survivre par rapport aux femmes, toutes choses égales par ailleurs. Ce résultat est cohérent avec la politique d'évacuation « les femmes et les enfants d'abord » appliquée lors du naufrage et corrobore les travaux antérieurs sur le sujet.

2.ii Hypothèse 2 : Effet de la classe sociale

L'influence de la classe de voyage sur la survie est **fortement confirmée**. Les passagers de troisième classe présentaient un risque de décès considérablement plus élevé, avec seulement 9,7% des chances de survie par rapport à ceux de première classe (OR = 0,097 ; $p < 0,001$). Les passagers de deuxième classe occupaient une position intermédiaire,

avec 29,2% des chances de survie comparativement à la première classe ($OR = 0,292$; $p < 0,001$).

Ces écarts peuvent s'expliquer par plusieurs facteurs structurels : la localisation des cabines (les passagers de première classe étaient logés sur les ponts supérieurs, plus proches des canots de sauvetage), un accès prioritaire à l'information et aux officiers chargés de l'évacuation, ainsi que des barrières physiques empêchant les passagers de troisième classe d'accéder rapidement au pont des embarcations.

2.iii Hypothèse 3 : Effet de l'âge

L'effet de l'âge est **confirmé et quantifié** : chaque année supplémentaire réduit les chances de survie d'environ 4,2% ($OR = 0,958$; $p < 0,001$). Ainsi, un passager de 50 ans avait environ 88% des chances de survie d'un enfant de 10 ans, toutes autres caractéristiques étant égales. Ce résultat valide la priorité accordée aux enfants lors de l'évacuation, bien que l'effet soit d'une ampleur plus modeste que celui du genre ou de la classe sociale.

2.iv Hypothèse 4 : Effet de la structure familiale

L'hypothèse concernant la structure familiale est **partiellement confirmée**. La variable **sibsp** (nombre de frères/sœurs ou conjoints à bord) exerce un effet négatif significatif : chaque membre supplémentaire de la fratrie ou conjoint réduit les chances de survie de 26,1% ($OR = 0,739$; $p = 0,001$). En revanche, la variable **parch** (parents/enfants à bord) n'a pas montré d'effet significatif et a été exclue du modèle final.

L'effet négatif de **sibsp** peut sembler contre-intuitif (l'entraide familiale aurait pu favoriser la survie). Une interprétation plausible est que les passagers accompagnés de membres de leur famille ont pu perdre un temps précieux à se rechercher mutuellement dans la panique, réduisant ainsi leurs chances d'atteindre les canots à temps. Alternativement, les familles nombreuses pouvaient rencontrer des difficultés à trouver des places ensemble dans les canots, retardant l'évacuation.

4.3 Comparaison des modèles AIC et BIC

La comparaison des deux modèles candidats révèle une situation intéressante sur le plan méthodologique :

- Le modèle AIC, incluant la variable **embarked**, présente un AIC plus faible (973,52 contre 978,83) et une AUC légèrement supérieure (0,8498 contre 0,8473).
- Le modèle BIC, plus parcimonieux, affiche des performances de classification légèrement meilleures sur toutes les métriques : exactitude (78,93% contre 77,39%), sensibilité (69,23% contre 67,31%), spécificité (85,35% contre 84,08%) et F1-score (0,7236 contre 0,7035).

Le test de DeLong ($p = 0,737$) indique que la différence entre les AUC n'est pas statistiquement significative. Ainsi, l'ajout de la variable **embarked** n'apporte pas de gain prédictif tangible sur l'échantillon de validation, malgré sa significativité statistique dans le modèle d'apprentissage.

Cette observation illustre un principe important en modélisation statistique : la significativité statistique d'une variable ne garantit pas nécessairement une amélioration de la capacité prédictive du modèle sur des données nouvelles. Le principe de parcimonie (rasoir d'Occam) militerait donc en faveur du modèle BIC, plus simple et aussi performant.

4.4 Limites de l'étude

Plusieurs limites doivent être soulignées :

1. **Valeurs manquantes** : L'imputation des âges manquants (20% de l'échantillon d'apprentissage) par la médiane conditionnelle, bien que préférable à une suppression des observations, introduit une incertitude dans les estimations. Des méthodes plus sophistiquées (imputation multiple, utilisation des titres extraits des noms) auraient pu être envisagées.
2. **Variables non disponibles** : Certaines informations potentiellement pertinentes ne figurent pas dans la base de données, comme la proximité de la cabine par rapport aux canots, l'heure d'arrivée sur le pont, ou la nationalité des passagers.

3. **Test de Hosmer-Lemeshow** : La p-value significative ($p = 0,005$) suggère formellement une mauvaise adéquation du modèle. Bien que ce test soit reconnu comme excessivement sensible pour les grands échantillons, ce résultat invite à la prudence dans l'interprétation.
4. **Performance prédictive modeste pour les survivants** : La sensibilité du modèle (67-69%) indique qu'environ un tiers des survivants ne sont pas correctement identifiés par les seules variables démographiques et socio-économiques. D'autres facteurs, possiblement aléatoires ou non documentés, ont joué un rôle dans la survie.

4.5 Implications et portée des résultats

Au-delà du cas historique du Titanic, cette étude illustre la méthodologie complète de la régression logistique dans un contexte de classification binaire. Les résultats confirment que les inégalités sociales ont joué un rôle déterminant dans l'issue du naufrage, la classe de voyage et le genre étant les deux prédicteurs les plus puissants de la survie.

Sur le plan statistique, l'analyse a mis en évidence l'importance de distinguer la significativité statistique de la pertinence prédictive, comme l'illustre le cas de la variable `embarked`. Elle souligne également la nécessité d'une validation rigoureuse sur un échantillon test indépendant pour évaluer objectivement les performances d'un modèle prédictif.

5 Conclusion

Ce travail avait pour objectif d'appliquer la méthodologie de la régression logistique à l'étude des facteurs de survie lors du naufrage du Titanic, en suivant rigoureusement les étapes prescrites : partition stratifiée des données, construction et sélection de modèles, tests d'adéquation, analyse des résidus et validation sur échantillon test.

L'analyse a permis de répondre clairement à la problématique posée. Les facteurs démographiques et socio-économiques expliquent une part substantielle de la variabilité de la survie. Le genre constitue le prédicteur le plus puissant : les hommes avaient 91,5% de chances en moins de survivre que les femmes. La classe sociale, mesurée par la classe de voyage, arrive en seconde position : les passagers de troisième classe avaient 90,3% de chances en moins que ceux de première classe. L'âge exerce un effet plus modeste mais significatif, chaque année supplémentaire réduisant les chances de survie de 4,2%. Enfin, la présence de membres de la fratrie ou d'un conjoint à bord (**sibsp**) diminue également les chances de survie, probablement en raison des difficultés de coordination dans la panique.

Deux modèles candidats ont été comparés. Le modèle AIC, incluant le port d'embarquement, et le modèle BIC, plus parcimonieux, présentent des performances prédictives très proches (AUC de 0,850 et 0,847 respectivement ; exactitude de 77,4% et 78,9%). Le test de DeLong confirme l'absence de différence significative entre les deux modèles. Le principe de parcimonie conduit à privilégier le modèle BIC, qui atteint une exactitude de 78,9% avec seulement quatre variables explicatives.

Sur le plan méthodologique, ce TP a permis de mettre en pratique l'ensemble des étapes d'une analyse de régression logistique sous R :

- La partition stratifiée des données garantit une évaluation non biaisée des performances prédictives ;
- L'imputation des valeurs manquantes sur l'échantillon d'apprentissage puis l'application des paramètres au test prévient la fuite d'information ;
- La vérification de la surdispersion ($\phi \approx 0,92$) a confirmé la pertinence du modèle logistique standard ;
- L'analyse des résidus et des distances de Cook a permis d'identifier les observations atypiques et influentes ;
- Les métriques de validation (matrice de confusion, courbe ROC, AUC) offrent

une évaluation objective de la capacité prédictive du modèle.

Les limites identifiées ouvrent des perspectives d'amélioration. L'imputation des âges pourrait être affinée en exploitant les titres de civilité extraits des noms des passagers. Des techniques de modélisation plus avancées (forêts aléatoires, gradient boosting) pourraient également être mises en œuvre pour tenter d'améliorer les performances prédictives, en particulier la sensibilité qui demeure modeste (69%). Enfin, une analyse plus fine des interactions entre variables (par exemple entre le genre et la classe sociale) pourrait révéler des effets croisés non capturés par le modèle additif actuel.

En définitive, cette étude confirme que le naufrage du Titanic, au-delà de son caractère accidentel, a agi comme un révélateur brutal des inégalités sociales de l'époque édouardienne. La modélisation statistique permet de quantifier objectivement ces inégalités et d'en mesurer l'impact sur la probabilité de survie des passagers.

Bibliographie

6 Webographie

- [1] Kaggle. (2012). *Titanic : Machine Learning from Disaster*. Consulté à l'adresse <https://www.kaggle.com/c/titanic/data>.
- [2] Encyclopedia Titanica. (2024). *Titanic Passenger and Crew Statistics*. Consulté à l'adresse <https://www.encyclopedia-titanica.org/titanic-statistics/>.

7 Annexes

Code R Utilisé

```
# =====  
# PROJET : Régression Logistique - Naufrage du Titanic  
# =====  
  
# -----  
# 1. CHARGEMENT DES PACKAGES ET DES DONNÉES  
# -----  
  
install.packages("skimr")  
  
library("tidyverse")  
library("ggplot2")  
library("readr")  
library("readxl")  
library("skimr")  
library("psych")  
  
Data <- read_excel("C:/Users/ADMIN/OneDrive/Bureau/Projets GLM/Titanic_dataset.xls")  
  
view(Data)  
describe(Data)  
summary(Data)  
glimpse(Data)  
  
# -----  
# 2. NETTOYAGE PRÉLIMINAIRE  
# -----  
  
# Suppression des variables non pertinentes
```

```
colonnes_a_garder <- c("pclass", "survived", "sex", "age", "sibsp", "parch", "fare",
Data_clean <- Data[, colonnes_a_garder]

glimpse(Data_clean)
summary(Data_clean)

# -----
# 3. PARTITION STRATIFIÉE TRAIN/TEST (80% / 20%)
# -----

library(caret)

set.seed(123)

index_train <- createDataPartition(Data_clean$survived, p = 0.8, list = FALSE)

train_data <- Data_clean[index_train, ]
test_data  <- Data_clean[-index_train, ]

cat("Dimensions Train :", dim(train_data), "\n")
cat("Dimensions Test  :", dim(test_data), "\n\n")

cat("Proportion survivants - Complet :", round(mean(Data_clean$survived) * 100, 2), "%\n")
cat("Proportion survivants - Train   :", round(mean(train_data$survived) * 100, 2), "%\n")
cat("Proportion survivants - Test    :", round(mean(test_data$survived) * 100, 2), "%\n")

# -----
# 4. TRAITEMENT DES VALEURS MANQUANTES SUR TRAIN
# -----

str(train_data)
summary(train_data)
```

```
cat("\n--- Valeurs manquantes dans Train ---\n")
colSums(is.na(train_data))

# 4.1 Imputation de embarked (mode)
mode_embarked <- names(sort(table(train_data$embarked), decreasing = TRUE))[1]
train_data$embarked[is.na(train_data$embarked)] <- mode_embarked
cat("Mode embarked :", mode_embarked, "\n")

# 4.2 Imputation de fare (médiane)
mediane_fare <- median(train_data$fare, na.rm = TRUE)
train_data$fare[is.na(train_data$fare)] <- mediane_fare
cat("Médiane fare :", mediane_fare, "\n")

# 4.3 Imputation de age (médiane conditionnelle pclass × sex)
library(dplyr)

age_medians <- train_data %>%
  group_by(pclass, sex) %>%
  summarise(median_age = median(age, na.rm = TRUE), .groups = 'drop')

cat("\n--- Médianes d'âge par Classe et Sexe ---\n")
print(age_medians)

imputer_age <- function(row) {
  if (is.na(row['age'])) {
    median_val <- age_medians %>%
      filter(pclass == as.numeric(row['pclass']), sex == row['sex']) %>%
      pull(median_age)
    return(median_val)
  } else {
    return(as.numeric(row['age']))
  }
}
```

```

    }
}

```

```
train_data$age <- apply(train_data[, c('pclass', 'sex', 'age')], 1, imputer_age)
```

```
cat("\n--- NA après traitement dans Train ---\n")
print(colSums(is.na(train_data)))
```

```
# 4.4 Conversion en facteurs
```

```
train_data$pclass <- as.factor(train_data$pclass)
train_data$sex <- as.factor(train_data$sex)
train_data$embarked <- as.factor(train_data$embarked)
train_data$survived <- as.factor(train_data$survived)
```

```
str(train_data)
```

```
# -----
# 5. MODÈLE DE RÉGRESSION LOGISTIQUE COMPLET
# -----
```

```
modele_complet <- glm(survived ~ pclass + sex + age + sibsp + parch + fare + embarked
                      data = train_data,
                      family = binomial)
```

```
summary(modele_complet)
exp(coef(modele_complet))
```

```
# -----
# 6. MODÈLE RÉDUIT ET COMPARAISON
# -----
```

```
modele_reduit <- glm(survived ~ pclass + sex + age + sibsp + embarked,
```

```

        data = train_data,
        family = binomial)

summary(modele_reduit)
anova(modele_reduit, modele_complet, test = "Chisq")

# -----
# 7. TEST DE SURDISPERSION
# -----

phi_complet <- deviance(modele_complet) / df.residual(modele_complet)
cat("Paramètre de dispersion (modèle complet) :", round(phi_complet, 4), "\n")

phi_reduit <- deviance(modele_reduit) / df.residual(modele_reduit)
cat("Paramètre de dispersion (modèle réduit)   :", round(phi_reduit, 4), "\n")

# -----
# 8. SÉLECTION AUTOMATIQUE (STEPWISE AIC ET BIC)
# -----

modele_step <- glm(survived ~ pclass + sex + age + sibsp + parch + fare + embarked,
                  data = train_data,
                  family = binomial)

# Stepwise AIC
modele_stepwise <- step(modele_step, direction = "both", trace = TRUE)
summary(modele_stepwise)
cat("\nAIC du modèle stepwise :", AIC(modele_stepwise), "\n")

# Stepwise BIC
modele_bic <- step(modele_step, direction = "both", k = log(nrow(train_data)), trace = TRUE)
summary(modele_bic)

```

```

cat("\n--- Comparaison AIC / BIC ---\n")
cat("AIC stepwise :", AIC(modele_stepwise), "\n")
cat("BIC stepwise :", BIC(modele_stepwise), "\n")
cat("AIC BIC      :", AIC(modele_bic), "\n")
cat("BIC BIC      :", BIC(modele_bic), "\n")

# Odds ratios du modèle stepwise
exp(coef(modele_stepwise))

# -----
# 9. TESTS D'ADÉQUATION
# -----

library(ResourceSelection)

# Test de Hosmer-Lemeshow
hoslem_test <- hoslem.test(as.numeric(as.character(train_data$survived)),
                           fitted(modele_stepwise), g = 10)
print(hoslem_test)

# Pseudo-R2 de McFadden
null_deviance <- modele_stepwise$null.deviance
resid_deviance <- modele_stepwise$deviance
mcfadden_R2 <- 1 - (resid_deviance / null_deviance)
cat("\nR2 McFadden =", round(mcfadden_R2, 4), "\n")

# Pseudo-R2 de Nagelkerke
install.packages("fmsb")
library(fmsb)
nagelkerke_R2 <- NagelkerkeR2(modele_stepwise)
cat("\nR2 Nagelkerke : \n")

```

```
print(nagelkerke_R2)

# -----
# 10. ANALYSE DES RÉSIDUS
# -----

residus_pearson <- residuals(modele_stepwise, type = "pearson")
residus_deviance <- residuals(modele_stepwise, type = "deviance")
cook_dist      <- cooks.distance(modele_stepwise)

diagnostics <- data.frame(
  obs      = 1:nrow(train_data),
  pearson  = residus_pearson,
  deviance = residus_deviance,
  cook     = cook_dist,
  survived = train_data$survived,
  fitted   = fitted(modele_stepwise)
)

cat("--- Résidus de Pearson extrêmes (|res| > 3) ---\n")
print(diagnostics[abs(diagnostics$pearson) > 3, ])

seuil_cook <- 4 / nrow(train_data)
cat("\n--- Observations influentes (Cook >", round(seuil_cook, 6), ") ---\n")
print(diagnostics[diagnostics$cook > seuil_cook, ])

cat("\n--- Résumé des résidus de Pearson ---\n")
print(summary(diagnostics$pearson))

cat("\n--- Résumé des résidus de déviance ---\n")
print(summary(diagnostics$deviance))
```

```
# Graphiques diagnostiques

png("diagnostics_residus.png", width = 800, height = 800)
par(mfrow = c(2, 2))

plot(diagnostics$fitted, diagnostics$pearson,
     xlab = "Probabilités prédites", ylab = "Résidus de Pearson",
     main = "Résidus de Pearson vs Prédites")
abline(h = 0, col = "red", lty = 2)
abline(h = c(-2, 2), col = "blue", lty = 2)
lines(lowess(diagnostics$fitted, diagnostics$pearson), col = "green", lwd = 2)

plot(diagnostics$fitted, diagnostics$deviance,
     xlab = "Probabilités prédites", ylab = "Résidus de déviance",
     main = "Résidus de déviance vs Prédites")
abline(h = 0, col = "red", lty = 2)
lines(lowess(diagnostics$fitted, diagnostics$deviance), col = "green", lwd = 2)

plot(diagnostics$obs, diagnostics$cook, type = "h",
     xlab = "Observation", ylab = "Distance de Cook",
     main = "Distances de Cook")
abline(h = seuil_cook, col = "red", lty = 2)

qqnorm(diagnostics$deviance, main = "QQ-plot des résidus de déviance")
qqline(diagnostics$deviance, col = "red")

dev.off()

# Histogramme

png("histogramme_residus.png", width = 600, height = 500)
hist(diagnostics$pearson, breaks = 30, col = "lightblue",
     main = "Distribution des résidus de Pearson",
     xlab = "Résidus de Pearson", probability = TRUE)
```

```

lines(density(diagnostics$pearson), col = "red", lwd = 2)
curve(dnorm(x, mean = mean(diagnostics$pearson), sd = sd(diagnostics$pearson)),
      add = TRUE, col = "blue", lwd = 2, lty = 2)
legend("topright", legend = c("Densité observée", "Normale théorique"),
      col = c("red", "blue"), lwd = 2, lty = c(1, 2))
dev.off()

# -----
# 11. PRÉPARATION DE L'ÉCHANTILLON TEST
# -----

cat("--- Paramètres du Train à appliquer au Test ---\n")
cat("Mode embarked :", mode_embarked, "\n")
cat("Médiane fare :", mediane_fare, "\n")

test_data$embarked[is.na(test_data$embarked)] <- mode_embarked
test_data$fare[is.na(test_data$fare)] <- mediane_fare
test_data$age <- apply(test_data[, c('pclass', 'sex', 'age')], 1, imputer_age)

test_data$pclass <- as.factor(test_data$pclass)
test_data$sex <- as.factor(test_data$sex)
test_data$embarked <- as.factor(test_data$embarked)
test_data$survived <- as.factor(test_data$survived)

cat("\n--- NA dans test_data après imputation ---\n")
print(colSums(is.na(test_data)))

# -----
# 12. VALIDATION - MODÈLE AIC
# -----

pred_probs <- predict(modele_stepwise, newdata = test_data, type = "response")

```

```

pred_classes <- ifelse(pred_probs > 0.5, 1, 0)
pred_classes <- as.factor(pred_classes)

test_data$pred_survived <- pred_classes
test_data$pred_prob      <- pred_probs

library(caret)

conf_matrix_aic <- confusionMatrix(test_data$pred_survived, test_data$survived, posit
print(conf_matrix_aic)

cat("\n--- Métriques AIC ---\n")
cat("Accuracy   :", round(conf_matrix_aic$overall['Accuracy'] * 100, 2), "%\n")
cat("Sensibilité:", round(conf_matrix_aic$byClass['Sensitivity'] * 100, 2), "%\n")
cat("Spécificité:", round(conf_matrix_aic$byClass['Specificity'] * 100, 2), "%\n")
cat("Précision  :", round(conf_matrix_aic$byClass['Precision'] * 100, 2), "%\n")
cat("F1-Score   :", round(conf_matrix_aic$byClass['F1'], 4), "\n")

# -----
# 13. VALIDATION - MODÈLE BIC
# -----

pred_probs_bic <- predict(modele_bic, newdata = test_data, type = "response")
pred_classes_bic <- ifelse(pred_probs_bic > 0.5, 1, 0)
pred_classes_bic <- as.factor(pred_classes_bic)

test_data$pred_survived_bic <- pred_classes_bic
test_data$pred_prob_bic     <- pred_probs_bic

conf_matrix_bic <- confusionMatrix(pred_classes_bic, test_data$survived, positive = "

cat("\n--- Métriques BIC ---\n")

```

```

cat("Accuracy    :", round(conf_matrix_bic$overall['Accuracy'] * 100, 2), "%\n")
cat("Sensibilité:", round(conf_matrix_bic$byClass['Sensitivity'] * 100, 2), "%\n")
cat("Spécificité:", round(conf_matrix_bic$byClass['Specificity'] * 100, 2), "%\n")
cat("Précision   :", round(conf_matrix_bic$byClass['Precision'] * 100, 2), "%\n")
cat("F1-Score    :", round(conf_matrix_bic$byClass['F1'], 4), "\n")

# -----
# 14. TABLEAU COMPARATIF AIC vs BIC
# -----

comparaison <- data.frame(
  Métrique    = c("Accuracy", "Sensibilité", "Spécificité", "Précision", "F1-Score"),
  AIC = c(round(conf_matrix_aic$overall['Accuracy'] * 100, 2),
    round(conf_matrix_aic$byClass['Sensitivity'] * 100, 2),
    round(conf_matrix_aic$byClass['Specificity'] * 100, 2),
    round(conf_matrix_aic$byClass['Precision'] * 100, 2),
    round(conf_matrix_aic$byClass['F1'], 4)),
  BIC = c(round(conf_matrix_bic$overall['Accuracy'] * 100, 2),
    round(conf_matrix_bic$byClass['Sensitivity'] * 100, 2),
    round(conf_matrix_bic$byClass['Specificity'] * 100, 2),
    round(conf_matrix_bic$byClass['Precision'] * 100, 2),
    round(conf_matrix_bic$byClass['F1'], 4))
)
print(comparaison)

# -----
# 15. COURBES ROC ET TEST DE DELONG
# -----

library(pROC)

roc_aic <- roc(test_data$survived, test_data$pred_prob, levels = c("0", "1"))

```

```

roc_bic <- roc(test_data$survived, pred_probs_bic, levels = c("0", "1"))

cat("\n--- Comparaison des AUC ---\n")
cat("AUC - AIC :", round(auc(roc_aic), 4), "\n")
cat("AUC - BIC :", round(auc(roc_bic), 4), "\n")

test_roc <- roc.test(roc_aic, roc_bic, method = "delong")
cat("\n--- Test de DeLong ---\n")
cat("p-value :", round(test_roc$p.value, 4), "\n")

# Tracé comparatif
png("courbes_roc_comparees.png", width = 700, height = 600)
plot.roc(roc_aic, main = "Comparaison des Courbes ROC - AIC vs BIC",
         col = "blue", lwd = 3, print.auc = TRUE,
         print.auc.x = 0.5, print.auc.y = 0.4, print.auc.cex = 1.1)
lines.roc(roc_bic, col = "red", lwd = 3)
legend("bottomright",
      legend = c(paste("AIC (AUC =", round(auc(roc_aic), 4), ")"),
                 paste("BIC (AUC =", round(auc(roc_bic), 4), ")")),
      col = c("blue", "red"), lwd = 3, bty = "n")
dev.off()

# =====
# FIN DU CODE
# =====

```